

广义线性模型

S.T.L

2021 年 10 月 31 日

目录

第一章 广义线性模型	1
1.1 引入	1
1.2 指数分布族	2
1.3 广义线性模型的结构	2
1.4 得分函数与信息矩阵	3
1.5 附注（一些推导）	6
1.6 参考资料 & 一些题外话	7

第一章 广义线性模型

概述

现有一随机变量（也可以是向量） Y 与 p 维变量 $X = (X_1, \dots, X_p)$ ，两者之间存在这某种统计关系，其中 Y 是来自由某一列参数 $\gamma = (\theta, \phi)$ 确定的分布族（此处我们讨论指数分布族）， X 对 Y 的影响体现在 $\gamma = (\theta, \phi)$ 中的 θ 上，具体的有映射 $K: \mathcal{X} \rightarrow \Theta, \theta = K(X)$ ，而 ϕ 的取值与 X 无关，为讨厌参数。对给定的 X ，我们可以确定 Θ ，同时如果对 ϕ 存在某些假设（如线性回归中的 σ^2 为常数），就可以确定 Y 的分布。

但是映射 K 的具体形式往往是不知道的，其未知性包含两点：1. θ 与 X 之间是一种什么关系（线性、二次、logit……）；2. θ 与 X 之间满足这种关系后某些系数的取值。

由于 $K(x_1, \dots, x_p)$ 是一个 p 元函数，对多元函数的处理是非常麻烦的，我们希望对 $x = (x_1, \dots, x_p)$ 作某种变换，得到更好处理的单一变元 η 再与 θ 建立联系。很直观的想法是对 X 作线性假设，令 $\eta = X\beta$ 。（这种做法实用性很广泛，在线性回归中我们发现很多关系都可以转化成线性关系（如多项式、乘积式作对数变换等，参见非线性回归））这里我们研究一类基于线性关系建立起的模型，即 $K(x) = h(\eta) = h(X\beta)$ 。

于是我们只需要选取某个特定的映射对 θ 与 η 建立联系（注意，这个联系是人为选取的，不同的联系会产生不同的模型，甚至某些选取完全是错误的，比如对指数模型作线性回归，无论作什么处理都不会得到很好的拟合结果），就可以建立 Y 与 X 之间的联系，而整个模型中需要估计的参数只有 β 。

理解广义线性模型的核心在于理解各个变量的含义及其相互的联系，其他内容基本都是多元情形下的数理统计的概念。因此在这里先列出各个记号及映射关系，其中可能有部分变量和函数在概述中没有提及，在后续会展开解释。

$$\begin{array}{ccccccc}
 & & \xi = \mu^{-1}(h(\eta)) & & & & \\
 & & \curvearrowright & & & & \\
 \mathbf{X} & \xrightarrow{\eta = X\beta} & \eta & \xleftrightarrow[h(\mu)]{h(\eta)} & \mu & \xleftrightarrow[b'(\theta)]{\mu^{-1}} & \theta \longrightarrow l(Y, \theta) \\
 q \times p & & q \times 1 & & q \times 1 & & q \times 1
 \end{array}$$

1.1 引入

在一般线性回归中，响应变量 Y 与设计矩阵 X 之间存在着统计关系

$$Y = X\beta + \epsilon$$

其中 $\mathbb{E}[\epsilon_i] = 0, \text{Cov}[\epsilon] = \sigma^2 I$ ，特别的可取 $\epsilon \sim N_p(\mathbf{0}, \sigma^2 I)$ 。

对上述模型，可以有另一种理解：

$$Y_i \sim N(\mu_i, \sigma^2) \quad \mathbb{E}[Y_i] = \mu_i \quad \mu_i = \eta_i = X_i\beta \quad (1.1)$$

这里我们引入了变量 $\eta_i = X_i\beta$, 来表示自变量 X_i 在 β 下的线性组合.

从而我们希望当 Y 不再服从正态分布, 而是其他某种已知的分布时, 建立 Y 与 $\eta = X\beta$ 之间的一种联系? 考虑到 Y 是一个随机变量, 因此需要寻找一个与 Y 相关的定量来描述 Y 的特性, 因此模仿线性回归, 我们希望建立 $\mathbb{E}[Y]$ 与 η 之间的关系. 因此我们将1.1改写称如下形式

$$Y_i \sim f(\theta, \phi) \quad \mathbb{E}[Y_i] = \mu_i \quad g(\mu_i) = \eta_i = X_i\beta \quad (1.2)$$

上述三个元素就组成了广义线性模型 (后续会对这三个元组给出具体说明).

1.2 指数分布族

为便于建立各个变量与参数之间的关系 (求导、求期望等), 广义线性模型要求随机变量 Y 的分布来自指数分布族. 在介绍广义线性模型前, 我们先来考察一些指数分布族的一些性质

定义 1.1. 称随机向量 Y 来自 **指数分布族**, 若其概率密度函数可以写成

$$f_Y(y, \theta) = a(\theta)b(y) \exp\{y'Q(\theta)\}$$

一个更一般的参数化密度函数允许包含一些讨厌参数或扩散参数 ϕ . 此时我们将其密度函数写称如下形式

$$f(\mathbf{y}; \boldsymbol{\theta}, \phi) = \exp \left\{ \frac{\mathbf{y}'\boldsymbol{\theta} - b(\boldsymbol{\theta})}{a(\phi)} + c(\phi, \mathbf{y}) \right\} \quad (1.3)$$

其中 $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^q$ 称为 **自然参数**; ϕ 未知, 称为 **扩散参数** 或 **讨厌参数**. 对给定的 ϕ 称 Θ 为 **自然参数空间**, 即所有满足下式的集合

$$0 < \int \exp\{\mathbf{y}'\boldsymbol{\theta}/a(\phi) + c(\phi, \mathbf{y})\} d\mathbf{y} < \infty$$

此时 Θ 是凸的.

定理 1.1. 若 Y 来自上述指数分布族, 则

$$\mathbb{E}_{\boldsymbol{\theta}}[Y] = \frac{\partial b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \quad \text{Cov}_{\boldsymbol{\theta}}[Y] = a(\phi) \frac{\partial^2 b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'} \triangleq \Sigma(\boldsymbol{\theta}) \quad (1.4)$$

1.3 广义线性模型的结构

一个 GLM 由三个部分组成, 在介绍这三个部分时, 我们先对我们拥有的观测结数据做一些解释: $X = \{X_1, \dots, X_N\}$ 是我们收集到的 N 个 $q \times p$ 维的协变量 (有一些书中将 X 定义为不含常数 1 列的变量, 而用 Z 表示 $(1, X)$, 而此处, 我们的 X 与 Z 表示同一个量), 与之对应的有 N 个 $q \times 1$ 维的观测结果 $Y = \{Y_1, \dots, Y_N\}$.

这其实是我们常见的数据的推广, 在学习回归的过程中, 我们接触到的往往是 N 个 1 维的响应变量 Y , 以及 N 个 p 维的协变量 X , 即上述数据中取 $q = 1$ 的情形. 实际上, 我们接触到的大部分模型都是 $p = 1$ 的, 但为了让我们的模型更具泛用性, 我们直接研究 $p \geq 1$ 时的情形.

下面我们来看 GLM 的三个部分:

1. **随机部分**: 建立起了 $l(\theta, Y_i)$ 与 θ 以及 μ 之间的联系.

随机部分的 Y 由 N 个观测值 $Y = \{Y_1, \dots, Y_N\}$ 组成. 每个 Y_i 相互独立且来自相同 $q \times 1$ 维未知参数 $\boldsymbol{\theta}$ 决定的指数分布族. 考虑单个随机向量 Y_i 的指数分布族, 并结合1.1则有

$$\mu_i \triangleq \mathbb{E}[Y_i] = \frac{\partial b_i(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \left(\frac{\partial b_i}{\partial \theta_1}, \dots, \frac{\partial b_i}{\partial \theta_N} \right)'$$

2. 系统部分: 这一部分建立起了 X 与 η 之间的联系.

系统部分是一组解释变量构成的线性模型

$$\eta_i = X_i \beta$$

其中 η_i 叫做线性预报; X_i 是 $q \times p$ 维矩阵 ($i = 1, \dots, N$), 是对解释变量的一组观测值; β 是一组 p 维未知常向量.

3. 连接函数: 这一部分建立起了 μ 与 η 之间的联系

记 $E[Y_i] = \mu_i$ 则连接函数可写作

$$g(\mu_i) = \eta_i = X_i \beta \quad i = 1, \dots, N$$

其中 $g: \mathcal{H} \rightarrow \mathbb{R}^q, \mathcal{H} \subset \mathbb{R}^q$ 是一个可逆且可微的函数 (在一元情形下往往取作单调函数).

又由 $g(\mu)$ 可逆可微知其存在反函数 $h: \mathbb{R}^q \rightarrow \mathcal{H}, h(\eta) = g^{-1}(\eta)$, 称为响应函数.

当 $g(\mu)$ 与 $\mu = b'(\theta)$ 都给定时, 我们还能直接写出 $\eta \rightarrow \theta$ 的映射 $\xi(\eta)$.

$g(\mu)$ 的几个特殊情形:

- (1) 自连接 (identity link): $g(\mu) = \mu$
- (2) 自然连接 (canonical link): $g(\mu(\theta)) = \theta$. 由1.1知, 自然连接满足 $g(\mu_i) = b'^{-1}(\mu_i)$.

下面给出一些自然函数习惯上的选取方式:

- (1) 如果响应变量的观察值是连续型数据, 同时又比较对称, 这时可以假定随机变量来自于正态总体.
- (2) 如果选择正态总体而连结函数是自然连结函数, 这就成了普通的线性回归 (读者可自行验证以加强对自然连接函数的理解).
- (3) 如果响应变量的观察值是非负的连续型数据, 则可应用 Γ 分布来构造广义线性回归模型.
- (4) 如果数据是非对称的生命数据, 就可以应用逆高斯分布来构造广义线性回归模型.

1.4 得分函数与信息矩阵

首先我们需要对模型作一些必要的假设:

- β 的可容许参数空间 B 是开的
- 对所有参数 $\beta \in B, h(Z_i \beta) \in y$ 其中 $i = 1, 2, \dots, Z_i$ 为 $q \times p$ 的设计矩阵 (这里我们不再用 X_i , 而是使用 Z_i !!!), y 为 Y 的均值取值空间.
- h, g 与 ξ 是二阶可微的, 且 $\det(\partial g / \partial \eta) \neq 0$.
- 对足够大的 n , $\sum_{i=1}^n Z_i Z_i'$ 满秩.

这一块由于主要就是计算, 所以基本就是抄周勇老师的广义估计方差估计方法 P244-246 的内容, 但由于这部分内容比较简略, 会在文末会对 $S_i(\beta)$ 与 $F_i(\beta)$ 的推导作出一些解释.

考察 Y 的似然函数 (likelihood function)

$$L(\theta, \phi; Y) = \prod_{i=1}^N \exp \left\{ \frac{\mathbf{Y}_i' \boldsymbol{\theta}_i - b(\boldsymbol{\theta}_i)}{a(\phi)} + c(\mathbf{Y}_i, \phi) \right\} \quad (1.5)$$

其对数似然函数可以写成

$$l(\theta, \phi; Y) = \sum_{i=1}^N \left\{ \frac{\mathbf{Y}_i' \boldsymbol{\theta}_i - b(\boldsymbol{\theta}_i)}{a(\phi)} + c(\mathbf{Y}_i, \phi) \right\} \quad (1.6)$$

对数似然函数对 θ 的一阶导函数组成的向量函数称为得分函数 (score function) .

$$\mathbf{S}(\boldsymbol{\theta}) = \frac{\partial l}{\partial \boldsymbol{\theta}} = \sum_{i=1}^N \mathbf{S}_i(\boldsymbol{\theta}) \quad (1.7)$$

将 $a(\phi)$ 视作讨厌参数, 于是得到相应的估计方程:

$$\frac{\partial l}{\partial \boldsymbol{\theta}} = \sum_{i=1}^N \frac{Y_i - \boldsymbol{\mu}_i}{a_i(\phi)} = 0 \quad (1.8)$$

而在实际的广义线性模型中, 我们感兴趣的是未知参数 $\boldsymbol{\beta}$, 每个观测值 Y_i 对 $\boldsymbol{\beta}$ 的对数似然作出的贡献可记为

$$l_i(\boldsymbol{\beta}) = [\mathbf{Y}_i' \boldsymbol{\theta}_i - b(\boldsymbol{\theta}_i)] / a_i(\phi) \quad (1.9)$$

每个个体关于 $\boldsymbol{\beta}$ 的分函数为 $\mathbf{S}_i(\boldsymbol{\beta}) = \partial l_i / \partial \boldsymbol{\beta}$ 由此可得

$$\begin{aligned} \mathbf{S}_i(\boldsymbol{\beta}) &= \frac{\partial \mathbf{h}(Z_i \boldsymbol{\beta})}{\partial \boldsymbol{\beta}} \Sigma_i^{-1}(\boldsymbol{\beta}) (Y_i - \boldsymbol{\mu}_i(\boldsymbol{\beta})) \\ &= Z_i' D_i(\boldsymbol{\beta}) \Sigma_i^{-1}(\boldsymbol{\beta}) (Y_i - \boldsymbol{\mu}_i(\boldsymbol{\beta})) \end{aligned} \quad (1.10)$$

其中 $D_i(\boldsymbol{\beta}) = \frac{\partial \mathbf{h}(\boldsymbol{\eta})}{\partial \boldsymbol{\eta}}$ 是 $\mathbf{h}(\boldsymbol{\eta})$ 的雅可比矩阵在 $\boldsymbol{\eta}_i = Z_i \boldsymbol{\beta}$ 的值, $\Sigma_i(\boldsymbol{\beta}) = v(\mathbf{h}(Z_i \boldsymbol{\beta})) a_i(\phi)$. 上式还可以等价地写为

$$\mathbf{S}_i(\boldsymbol{\beta}) = Z_i' W_i(\boldsymbol{\beta}) \frac{\partial \mathbf{g}(\boldsymbol{\mu}_i)}{\partial \boldsymbol{\mu}'} (Y_i - \boldsymbol{\mu}_i(\boldsymbol{\beta})) \quad (1.11)$$

其中 W_i 是一个权矩阵

$$W_i(\boldsymbol{\beta}) = \left[\frac{\partial \mathbf{g}(\boldsymbol{\mu}_i)}{\partial \boldsymbol{\mu}'} \Sigma_i(\boldsymbol{\beta}) \frac{\partial \mathbf{g}(\boldsymbol{\mu}_i)}{\partial \boldsymbol{\mu}} \right]^{-1} = D_i \Sigma_i^{-1} D_i' \quad (1.12)$$

由此只需求解方程

$$\mathbf{S}(\boldsymbol{\beta}) = \frac{\partial l}{\partial \boldsymbol{\beta}} = \sum_{i=1}^N \frac{\partial l_i}{\partial \boldsymbol{\beta}} = \sum_{i=1}^N \mathbf{S}_i(\boldsymbol{\beta}) = 0 \quad (1.13)$$

即可得到 $\boldsymbol{\beta}$ 的极大似然估计 $\hat{\boldsymbol{\beta}}_n$.

得分函数及 Fisher 信息阵的性质

下面考察得分函数及其 Fisher 信息阵的一些性质首先对 \mathbf{S}_i , 其期望为 0:

$$\mathbb{E}_{\boldsymbol{\beta}} \mathbf{S}_i(\boldsymbol{\beta}) = Z_i' D_i(\boldsymbol{\beta}) \Sigma_i^{-1}(\boldsymbol{\beta}) (\mathbb{E}[Y_i] - \boldsymbol{\mu}_i(\boldsymbol{\beta})) = 0 \quad (1.14)$$

该统计结构的 Fisher 信息阵或期望信息阵为

$$F_i(\boldsymbol{\beta}) = \text{Cov}_{\boldsymbol{\beta}}(\mathbf{S}_i(\boldsymbol{\beta})) = \mathbb{E}_{\boldsymbol{\beta}}(\mathbf{S}_i(\boldsymbol{\beta}) \mathbf{S}_i'(\boldsymbol{\beta})) = Z_i' W_i Z_i \quad (1.15)$$

观察信息阵为

$$F_{i,obs}(\beta) = -\frac{\partial^2 l_i}{\partial \beta \partial \beta'} = F_i(\beta) - \frac{1}{a(\phi)} R_i(\beta) \quad (1.16)$$

其中

$$R_i(\beta) = \sum_{r=1}^q Z_i' U_{ir} Z_i (y_{ir} - \mu_{ir}(\beta)) \quad (1.17)$$

其中 $U_{ir} = \frac{\partial^2 \xi_i(Z_i \beta)}{\partial \eta \partial \eta'}$ 为 $q \times q$ 矩阵. (注意, 1.16 中 F 的表达式与很多介绍 GLM 的书都不同, 多了一项 $a(\phi)^{-1}$, 这一点将会在附注中说明.)

易证

$$\mathbb{E}_\beta[R_i(\beta)] = 0 \quad \mathbb{E}_\beta[F_{i,obs}(\beta)] = 0$$

由此可以证明在前述假设条件成立的情况下, 通过极大似然估计得到的 $\hat{\beta}_{ML}$ 是 β 的相合估计, 且具有渐近正态分布.

定理 1.2. 假设前述条件成立, 则

$$\begin{aligned} \hat{\beta}_n &\xrightarrow{P} \beta \\ \sqrt{n}(\hat{\beta}_n - \beta) &\xrightarrow{D} N(0, \Sigma^{-1}(\beta)) \end{aligned}$$

其中 $\Sigma(\beta) = \lim_{n \rightarrow \infty} n^{-1} \sum_{i=1}^n Z_i' W_i Z_i$.

这一部分本质上就是多元里的 MLE 的性质, 因此不展开具体证明.

可见 MLE 是对 GLM 中参数 β 的一个较好的估计.

#: 先介绍到这里吧, 后续随缘写一些假设检验和其他方面的拓展, 可能还会对二项分布展开介绍一下 (毕竟全篇没有例子). 属实是不想再敲笔记了 23333

另外, 别跑, 后面还有附注的证明. 敲了半天的公式 ==

1.5 附注（一些推导）

证明. 定理 1.1

$$\frac{\partial \ln f}{\partial \boldsymbol{\theta}} = \frac{1}{f} \frac{\partial f}{\partial \boldsymbol{\theta}} = \frac{1}{a(\phi)} \left\{ \mathbf{y} - \frac{\partial b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right\}$$

$$\frac{\partial^2 \ln f}{\partial \boldsymbol{\theta}^2} = \frac{1}{f^2} \left[\frac{\partial^2 f}{\partial \boldsymbol{\theta}^2} - \left(\frac{\partial f}{\partial \boldsymbol{\theta}} \right)^2 \right] = -\frac{1}{a(\phi)} \frac{\partial^2 b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top}$$

从而由正则化假设有

$$\begin{aligned} \mathbb{E}[Y] &= \int \mathbf{y} f d\mathbf{y} = \int a(\phi) \frac{\partial f}{\partial \boldsymbol{\theta}} d\mathbf{y} + \frac{\partial b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \frac{\partial b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \\ \text{Cov}[Y] &= \mathbb{E}(Y - \frac{\partial b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}})^2 = \int \left(\mathbf{y} - \frac{\partial b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right) f d\mathbf{y} \\ &= \int \frac{a^2}{f^2} \left(\frac{\partial f}{\partial \boldsymbol{\theta}} \right)^2 f d\mathbf{y} = \int a^2 \left(\frac{\partial^2 f}{\partial \boldsymbol{\theta}^2} + \frac{f}{a(\phi)} \frac{\partial^2 b}{\partial \boldsymbol{\theta}^2} \right) d\mathbf{y} = a(\phi) = \frac{\partial^2 b}{\partial \boldsymbol{\theta}^2} \end{aligned}$$

证明. 得分函数与 Fisher 信息阵相关的等式推导. 主要为 1.10, 1.16.

直接给出详细的证明往往是不讨喜的, 因此这部分建议自己推导.

首先我们列出几个的一阶偏导结果, 这些结果会在推导中反复用到 (注, 为方便书写, 将所有下标略去, 且不再对向量可以加粗 (因为实在太费时间了!))

$$\frac{\partial l}{\partial \theta'} = \left(y' - \frac{\partial b}{\partial \theta'} \right) / a(\phi) \quad (1.18)$$

$$\frac{\partial \theta}{\partial \mu'} = \left(\frac{\partial \mu}{\partial \theta'} \right)^{-1} = \left(\frac{\partial^2 b}{\partial \theta \partial \theta'} \right)^{-1} = a(\phi) \Sigma^{-1} \quad (1.19)$$

$$\frac{\partial \mu}{\partial \eta'} = D'(\beta) \quad (1.20)$$

$$\frac{\partial \eta}{\partial \beta'} = Z \quad (1.21)$$

其中 1.19 中用到了逆映射定理. 于是由链式法则, 有

$$\begin{aligned} S(\beta) &= \frac{\partial l}{\partial \beta} = \left(\frac{\partial l}{\partial \beta'} \right)' = \left(\frac{\partial l}{\partial \theta'} \frac{\partial \theta}{\partial \mu'} \frac{\partial \mu}{\partial \eta'} \frac{\partial \eta}{\partial \beta'} \right)' \\ &= Z' D \Sigma^{-1} (y - \mu(\beta)) \end{aligned} \quad (1.22)$$

同时上面的式子还可以写成

$$\frac{\partial l}{\partial \beta} = \left(\frac{\partial l}{\partial \theta'} \frac{\partial \theta}{\partial \eta'} \frac{\partial \eta}{\partial \beta'} \right)' = Z' \left(\frac{\partial \xi}{\partial \eta'} \right)' \left(y - \frac{\partial b}{\partial \theta} \right) / a(\phi) \quad (1.23)$$

其中可记

$$\left(\frac{\partial \xi}{\partial \eta'} \right)' = \begin{bmatrix} \frac{\partial \xi_1}{\partial \eta_1} & \cdots & \frac{\partial \xi_n}{\partial \eta_1} \\ \vdots & & \vdots \\ \frac{\partial \xi_1}{\partial \eta_n} & \cdots & \frac{\partial \xi_n}{\partial \eta_n} \end{bmatrix} = \left(\frac{\partial \xi_1}{\partial \eta}, \dots, \frac{\partial \xi_q}{\partial \eta} \right)$$

又记 $y - \mu = \tau = (\tau_1, \dots, \tau_q)'$, 则有

$$\begin{aligned} F_{i,obs}(\beta) &= -\frac{\partial^2 l}{\partial \beta \partial \beta'} = -\frac{\partial}{\partial \beta'} \left(\frac{\partial l}{\partial \beta} \right) \\ &= -Z' \sum_{i=1}^q \left(\tau_i \frac{\partial^2 \xi_i}{\partial \eta \partial \beta'} - \frac{\partial \xi_i}{\partial \eta} \frac{\partial \tau_i}{\partial \beta'} \right) / a(\phi) \\ &= - \left(Z' \sum_{i=1}^q \left(\tau_i \frac{\partial^2 \xi_i}{\partial \eta \partial \eta'} \frac{\partial \eta}{\partial \beta'} \right) + \left(\frac{\partial \xi}{\partial \eta'} \right)' \frac{\partial \tau}{\partial \beta'} \right) / a(\phi) \end{aligned} \quad (1.24)$$

其中

$$\frac{\partial \xi}{\partial \eta'} = \frac{\partial \theta}{\partial \mu'} \frac{\partial \mu}{\partial \eta'} = a(\phi) \Sigma^{-1} D' \quad (1.25)$$

$$\frac{\partial \tau}{\partial \beta'} = -\frac{\partial \mu}{\partial \beta} = -\frac{\partial \mu}{\partial \theta'} \frac{\partial \theta}{\partial \beta'} = -D' Z \quad (1.26)$$

代回 1.24, 即有

$$\begin{aligned} F_{i,bos}(\beta) &= Z' D \Sigma^{-1} D Z - \frac{1}{a(\phi)} \sum_{r=1}^q Z' \frac{\partial^2 \xi_r}{\partial \eta \partial \eta'} Z (y_r - \mu_r) \\ &= F_i(\beta) - \frac{1}{a(\phi)} R_i(\beta) \end{aligned} \quad (1.27)$$

没错这里与很多介绍 GLM 的书不同, 最终推导得到的公式中 R 项会多出一个系数 $a(\phi)^{-1}$. 最早可以追溯到 [Fahrmeir-Tutz,1994] 的著作中的附录 A, 那里就有遗漏. 当然可以去查看更原始的文献 [Nelder and Wedderburn,1972], 在另一种指数分布族的表达中建立了信息量的表达式, 目测那里的推导没有遗漏任何系数.

1.6 参考资料 & 一些题外话

老师上课用的是周勇老师的教材, 上来就考虑多元情形, 属实把我上傻了, 如果想系统地学习建议从 C. Radhakrishna Rao 入手, 作者从 Y 为一元随机变量入手开始介绍, 并举了很多常用的例子, 如果觉得有学习多元情形的需求, 再考虑阅读 Fahrmeir and Tutz 的书, 毕竟那本题目就有 multivariate. 当然我只是学了个大概, 然后到处抄书.

参考资料在这里列出, 因为实在懒, 就没搞严格的引用格式.

[Fahrmeir and Tutz,1994] Book Multivariate Statistical Model (Append A)

[Nelder and Wedderburn,1972] Generalized Linear Models

[C. Radhakrishna Rao, 1999] Generalized Linear Models (Chap 10)

[周勇,2013] 广义估计方程估计方法 (Chap 11)